합성 데이터와 객체 인식 알고리즘을 활용한 용접 결함 검출

심유나 ○, 강제원
이화여자대학교 인공지능융합전공
이화여자대학교 공과대학 전자전기공학과
syna2178@ewhain.net, jewonk@ewha.ac.kr

요 약

본 연구는 현대 제조업의 핵심 과제 중 하나인 용접 결함의 효율적인 탐지를 위해 딥러닝 기술을 기반으로 한 용접 결함 탐지 방법을 제안한다. 기존에 사용되던 용접 결함 검출 방식인 시각적 검사와 비파괴검사는 많은 시간과 비용을 필요로 하며, 검사의 정확성이 검사자의 경험과 기술에 따라 달라진다는 한계를 가지고 있었다. 이러한 기존 방식의 단점을 극복하고자, 본 연구에서는 실제 용접 공정에서 발생하는 다양한 용접 결함 유형의 합성 데이터셋을 제작하여 실험에 활용하였다. 또한, 본 연구에서는 합성 이미지 생성 과정에서 이미지 전처리 기법의 중요성을 인식하고, 실제적인 용접 결함 이미지 생성에 가장 적합하고 효과적인 전처리 기법을 선별하고 적용하였다. 또한, 전이학습을 통해 객체 탐지 알고리즘 YOLOv5 의 용접 결함 탐지 성능을 개선했다. 딥러닝 기반 합성 데이터 생성과 객체 탐지 기술 결합한 이 연구의 접근법은 다른 산업 분야에도 적용 가능하며, 이를 통해 제조 공정의 품질 관리와 안전성을 향상시키는 데 도움이 될 것으로 예상된다.

1. 서론

산업 현장에서 용접은 제품의 품질과 안정성에 결정적인 영향을 미치는 중요한 공정으로, 용접 과정에서 발생하는 결함은 제품의 성능 저하는 물론 심각한 경우 인명 피해까지 초래할 수 있어, 이를 효과적으로 관리하는 것은 제조업의 핵심 과제 중 하나다. 전통적인 용접 결함 검출 방식은 주로 시각적 검사나 비파괴검사를 통해 이루어졌으나, 이러한 방법들은 많은 비용과 시간을 요구하며, 검사 결과의 정확성이 검사자의 경험과 기술에 의존한다는 한계가 있었다[1].

이러한 기존 방법의 단점을 해결하고자, 본 연구에서는 딥러닝 기술을 활용한 새로운 용접 결함 탐지 방식을 제안한다. 딥러닝 기반의 객체 탐지 기술은 용접 결함 검출의 정확성과 효율성을 크게 향상시킬 수 있는 효과적인 방법 중 하나가 될 수 있다. 그러나 딥러닝 모델의 효과적인 학습을 위해서는 충분한 양과 높은 품질의 데이터가 필수적인데, 용접 결함 탐지를 위한 공개 데이터셋의 부재가 이 분야의 연구를 어렵게 만들었다.

이 문제를 해결하기 위해, 본 연구에서는 CycleGAN[2]을 이용하여 실제 용접 공정에서 발생할 수 있는 다양한 유형의 용접 결함을 포함한 합성 데이터셋을 제작하였다. 이렇게 생성된 합성 데이터는 다양한 용접 결함 상황을 모사하여 딥러닝 모델의 학습을 효과적으로 가능하게 한다. 또한, 합성 데이터 생성 과정에서 이미지 전처리 기술의 중요성을 인식하고, 다양한 전처리 방법들을 비교 분석함으로써 용접 결함 탐지에 최적화된 방법을 찾아냈다.

객체 인식 알고리즘으로는 YOLO(You Only Look Once)[3]을 선택하여 연구를 진행하였다. YOLO 는 실시간 객체 탐지 기능을 제공하는 동시에 빠른 처리 속도와 높은 탐지 정확도를 자랑하는 모델로, 이 중 YOLOv5 를 선택하여 실제 용접 공정에서 발생하는 다양한 용접 결함을 효과적으로 탐지할 수 있도록 하였다.

2. 관련 연구

2.1 YOLOv5

YOLOv5는 딥러닝 기반의 객체 인식 알고리즘으로, 빠른 속도와 높은 정확도로 다양한 객체를 탐지할 수 있는 것이 특징이다. 이

네트워크는 모델의 크기에 따라 여러 버전이 있으며, 각 버전은 특징 맵의 깊이와 너비, 그리고 계산량에서 차이가 있다. 모델의 크기가 클수록 더 많은 계산 리소스가 필요하지만, 더욱 정교한 탐지 능력을 가진다.

본 연구에서는 용접 결함 탐지라는 특정 목적에 맞추어 YOLOv5 의 가장 작은 모델인 YOLOv5s 를 선택하였다. 용접 결함 이미지의 경우 자연 이미지에 비해 상대적으로 적은 정보를 포함하고 있기에, 계산량을 줄이기 위한 선택이었다.

2.2 CycleGAN

CycleGAN 은 이미지-이미지 변환(image-to-image translation)을 위한 심층 학습 모델로, 서로 다른 두 도메인 간의 이미지를 변환하는 데 사용된다. CycleGA-N 의 핵심은 두 도메인 간의 이미지 변환을 가능하게 하는 것이며, 이를 위해 적대적 손실(Adversarial Loss)과 사이클 일관성 손실(Cycle Consistency Loss), 두 가지의 손실 함수를 사용한다. 이 두 손실 함수는 CycleGAN 이 실제 같은 이미지를 생성하면서도 원본 이미지와 변환된 이미지 간 일관성을 유지하도록 한다.

CycleGAN 은 두 개의 생성기가 각각 서로 다른 도메인으로의 이미지 변환을 담당한다. CycleG-AN 의 중요한 특징 중 하나는 페어링된 데이터셋이 필요 없다는 것이다. 즉, 도메인간의 직접적인 대응 관계가 없는 이미지들을 사용하여 학습할 수 있다. 이는 데이터 수집 과정을 단순화하고, 다양한 종류의 데이터셋에 적용될 수 있는 유연성을 제공한다.

3. 제안 방법

본 연구에서는 심층 학습 기반의 용접 결함 탐지를 위해 CycleGAN으로 합성 데이터를 생성하였다. 이를 위해 공개 데이터셋인 GD-Xray Welds[4] 와 RIAWELC[5]방사선 촬영 이미지를 이용하였다. 이 데이터셋들은 용접 부위의 방사선 촬영을 통해 얻은 이미지로 구성되어 있다.

하지만, 이러한 데이터는 흑백 이미지 형태라서 실제 용접 환경에서 카메라를 통해 얻어지는 RGB 컬러 이미지와는 상당한 차이가 있다. 이러한 차이를 극복하고자, CycleGAN 을 사용하여 흑백 방사선 이미지를 실제 용접 환경에서 얻을 수 있는 RGB 컬러 이미지 스타일로 변환하는 작업을 수행했다. 이는 딥러닝 모델이 실제 용접 환경과 더 유사한 데이터를 학습할 수 있게 하여, 모델의 일반화 능력과 실용성을 향상시킬 수 있다.

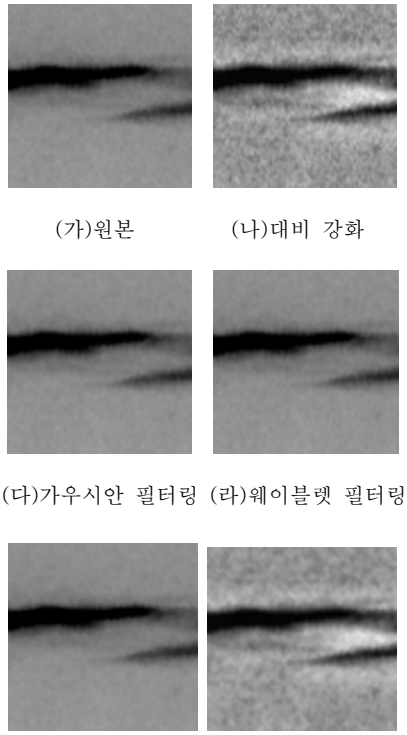

(가)원본 (나)대비 강화

(다)가우시안 필터링 (라)웨이블렛 필터링

(마)미디언 필터링 (바)모든 기법 적용

그림 1. 이미지 전처리 방법 비교 시각화

합성 이미지 제작 과정에서 원본 방사선 이미지에 대한 이미지 전처리 기법의 적용은 결과물의 질을 향상시키는 데 중요한 역할을 하였다. CycleGAN을 사용하여 합성 이미지를 생성하는 과정에서 원본 이미지에 대한 전처리 기법을 적용한 경우와 그렇지 않은 경우를 비교 분석한 결과, 이미지 전처리 기법을 적용한 경우가 실제와 더욱 유사한 이미지를 생성하는 데 효과적임을 확인하였다.

원본 이미지의 특징을 더욱 명확하게 드러내기 위해 대비를 강화함으로써 이미지의 세부 사항과 구조가 더욱 선명하게 나타나게 하였다. 그러나 대비를 강화하는 과정에서 발생하는 부작용으로 노이즈가 증가하였다. 이를 해결하기 위해 미디언 필터링, 가우시안 필터링, 웨이블렛 필터링을 순차적으로 적용하였다. 미디언 필터링은 극단적인 노이즈를 효과적으로 제거하면서도 이미지의 엣지를 잘 보존한다. 이어서 가우시안 필터링을 적용하여 이미지의 전반적인 노이즈 수준을 줄이고, 부드러운 텍스처를 생성하였다. 마지막으로 웨이블렛 필터링을 통해 이미지의 다양한 주파수 구성 요소를 세밀하게 조정하며, 중요한 특징을 강조하고 불필요한 세부 사항을 제거했다. 이러한 전처리 과정을 거친 이미지를 입력으로 사용하여 CycleGAN으로 처리함으로써 원본 이미지의 중요한 특징을 보존하는 실제적인 합성

이미지를 생성할 수 있었다.

용접 결함의 세 가지 주요 유형인 크랙(Crack), 기공(Porosity), 스패터(Spatter)에 대한 이미지 클래스를 생성했다. 각 클래스는 해당하는 결함 유형의 특징을 반영하는 이미지들로 구성되었으며, 이를 통해 딥러닝 모델이 각각의 실제 용접 결함 유형을 보다 정확하게 탐지하고 분류할 수 있도록 하였다.

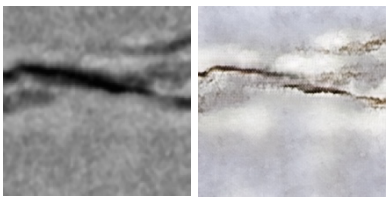

(가) 크랙 데이터 셋 (RIAWELC)

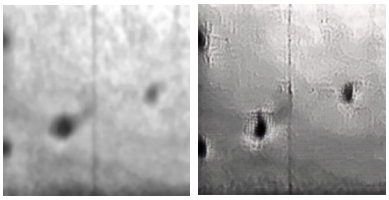

(나) 기공 데이터 셋 (RIAWELC)

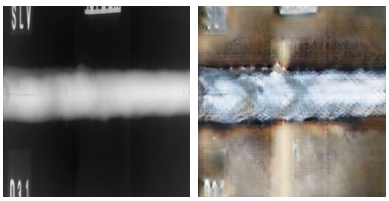

(다) 스패터 데이터 셋 (GD-Xray)

그림 2. 방사선 이미지 (좌측)과 CycleGAN을 이용해 생성한 RGB 합성 데이터 이미지(우측)

4. 실험 결과 및 분석

4.1 실험 환경

실험에서는 NVIDIA RTX A6000 4 개와 CUDA 11.4 버전, Python 3.8 버전을 사용했다. 학습에 사용한 데이터셋은 총 1,462 개의 합성 데이터 이미지를 포함하고 있다. 이는 원래 CycleGAN 으로 생성한 450 개의 데이터에 데이터 증강 기술을 적용하여 1,462 개로 확장한 것이다. 데이터 증강은 모델의 일반화 능력을 향상시키고, 과적합(overfitting)을 방지하는 데 도움이 된다. 테스트 데이터는 총 318 개의 합성 데이터 이미지로 구성되었다. 이 또한 원래 CycleGAN 으로 생성한 112 개의 데이터에 데이터 증강을 적용하여 확장한 것이다. 실험에 사용된 모든 이미지는 256x256 크기의 RGB 컬러 영상으로 처리된 후 이용되었다. 이 크기는 객체 탐지 작업에 적절한 해상도를 제공하며, 동시에 계산 효율성을 고려한 선택이었다.

4.2 정량적 평가

표 1. 용접 결함 탐지를 위한 YOLOv5s 모델의 성능 비교

학습 방법	mAP 0.5(%)	mAP 0.5:0.95(%)	정밀도	재현율	F1 점수
COCO-전이학습	85.2	55.3	88.1	82.7	85.3
CC-전이학습	82.6	53.7	85.4	80.9	83.1
이중 전이학습	87.5	58.2	90.3	85.1	87.6
전이학습 비적용	78.4	49.8	81.2	76.5	78.8

용접 결함 탐지를 위한 YOLOv5s 모델의 성능을 다양한 학습 조건 하에서 평가하였다. 표 1은 이러한 실험 조건들에 따른 모델의 임계값 0.5, 임계값 0.5부터 0.95까지에서의 평균 정밀도(Mean Average Precision), 정밀도, 재현율, F1 점수를 요약하여 보여준다. 실험 조건은 COCO 데이터셋[6]으로 사전학습 후 용접 결함 탐지 데이터셋으로 전이학습한 경우 (COCO-전이학습), Crater[7]와 Crack[8] 데이터셋으로 사전학습 후 전이학습한 경우(CC-전이학습), COCO 데이터셋으로 사전학습 후 Crater와 Crack 데이터셋으로 추가 전이학습한 경우(이중 전이학습), 그리고 전이학습 없이 용접 결함 탐지 데이터셋으로만 학습한 경우로 나누어 진행하였다. 이중 전이학습을 적용한 경우가 모든 평가 지표에서 가장 높은 성능을 보였으며, 이는 COCO 데이터셋의 광범위한 일반적 특징 학습과 Crater, Crack 데이터셋의 특정 도메인 특징 학습이 모델의 성능 향상에 기여한 것으로 해석할 수 있다. 반면, 전이학습 없이 진행된 실험은 상대적으로 낮은 성능을 보였으며, 이는 사전학습이 모델의 일반화 능력과 성능 향상에 중요한 역할을 한다는 것을 시사한다.

4.3 정성적 평가

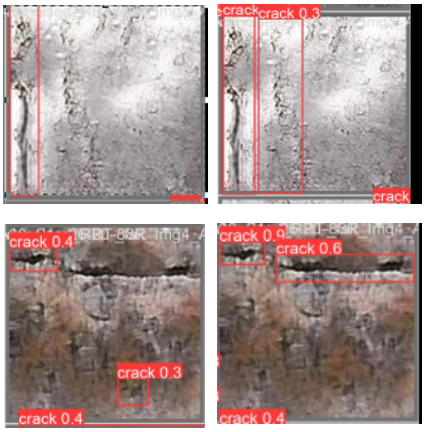

그림 3. COCO 데이터셋으로 사전학습 후 전이학습(좌측)과 이중 전이학습(우측) 결함 탐지 비교

그림 3 은 COCO 데이터셋을 사용한 사전학습 후 전이학습(좌측)과 이중 전이학습(우측)을 적용하여 용접 결함을 탐지한 결과를 비교한 것이다. 좌측 이미지에서 전이학습을 통해 얻어진 결과는 용접 결함을 일정 수준에서 탐지하는 능력을 보여주고 있으나, 결함의 위치를 정확히 특정 짓지 못하고 일부 누락된 결함들이 존재한다. 또한 결함이 아닌 부분에서 결함을 탐지하는 현상도 나타나고 있다. 반면, 이중 전이학습 방법이 적용된 우측 이미지에서는 결함의 다양한 크기와 형태를 더욱 세밀하게 탐지하고 있음을 알 수 있다.

4.4 한계점

본 연구의 주요 한계점 중 하나는 테스트 시에 실제 용접 결함 이미지를 사용하지 않은 것이다. 합성 데이터는 실제 용접 환경에서 발생할 수 있는 다양한 변수들을 완벽하게 반영하지 못할 수 있으며, 이로 인해 알고리즘의 실제 환경 적용성에 대한 평가가 제한적일 수 있다. 실제 용접 결함 데이터를 사용하여 알고리즘을 테스트하고 평가하는 것이 더 정확한 결과를 도출할 수 있다.

또 다른 한계점은 용접 전문가와의 협업 없이 연구가 진행되었다는 점이다. 용접 분야의 전문가는 결함의 다양한 형태와 특성을 정확하게 이해하고 있으며, 이러한 전문 지식은 합성 데이터 제작 및 알고리즘의 정확성 향상에 크게 기여할 수 있다. 전문가의 참여 없이 진행된 연구는 현장 적용성과 실제 결함 탐지 능력에 대한 정확한 평가에 한계를 가질 수 있다.

5. 결론

본 연구에서는 합성 데이터와 객체 인식 알고리즘을 활용하여 용접 결함을 검출하는 방법을 탐구하였다. 실험 결과, 이중 전이학습 방법이 가장 높은 성능을 보여주었으며, 이는 mAP 0.5 에서 87.5 %, mAP 0.5:0.95 에서 58.2%의 결과를 달성하였다. COCO 데이터셋으로 사전학습 후 전이학습을 적용한 방법도 우수한 성능을 나타냈지만, 이중 전이학습이 전반적으로 더 높은 정밀도와 재현율을 보였다. 반면, 전이학습을 적용하지 않은 경우에는 상대적으로 낮은 성능을 나타냈다. 전이학습의 적절한 적용이 용접 결함 검출의 정확성을 향상 시키는 데에 효과적이었음을 알 수 있었다. 본 연구는 용접 결함 검출 분야에서 실제 용접 환경에서 적용 가능한 딥러닝 기반 합성 데이터 생성과 객체 인식 알고리즘의 적용 가능성을 탐색하였으며, 이는 제조 공정의 품질 관리와 안정성 부분의 기술 발전에 기여할것으로 기대된다.

감사의 글

이 논문은 2023 년도 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원을 받아 수행된 연구임 (No.RS-2022-00155966, 인공지능융합혁신인재양성(이화여자대학교))

참고문헌

[1] P. Kah, B. Mvola, J. Martikainen, R. Suoranta, " Real Time Non-Destructive Testing Methods of Welding," Advanced Materials Research, vol. 933, pp. 109-116, 2014.

[2] Zhu, J.-Y., Park, T., Isola, P., & Efros, A. A. “ Unpaired Image-to-Image Translation Using Cycle -Consistent Adversarial Networks,” IEEE Internati onal Conference on Computer Vision (ICCV) pp. 2242-2251, 2017

[3] Redmon, S. Divvala, R. Girshick and A. Farhadi, "You Only Look Once: Unified, Real-Time Object Detection" 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 779-788, 2016.

[4] D. Mery, V. Riffo, U. Zscherpel, G. Mondragón, I. Lillo, I. Zuccar, H. Lobel, M. Carrasco, "GDX ray: The Database of X-ray Images for Nondestru ctive Testing," Journal of Nondestructive Evaluati on, vol. 34, no. 4, 2015.

[5] B. Totino, F. Spagnolo, S. Perri, "RIAWELC: A Novel Dataset of Radiographic Images for Autom atic Weld Defects Classification," International Jo urnal of Engineering and Emerging Technologies, vol. 1, no. 1, pp. 1-10, 2023.

[6] Lin, T.-Y., Maire, M., Belongie, S. J., Hays, J., Perona, P., Ramanan, D., Dollár, P., & Zitnick, C. L., “Microsoft COCO: Common Objects in Co -ntext,” European Conference on Computer Vision

pp. 740-755, 2014
[7] La Grassa, R, "LU3M6TGT Dataset" Retrieved from Kaggle: https://www.kaggle.com/datasets/riccardolagrassa/lu3m6tgt, 2023
[8] AY 7aga, "Building Defects Dataset" Retrieved from Roboflow Universe: https://universe.roboflow.com/ay-7aga/building-defects-uqoih, 2023